

# K-NET AI Study Group

Hyungyu Kim

K-NET

03 Sep 2024

# 원래 주제는 “pix2pix”였는데...

- pix2pix 논문 중에 GAN이라고 하는 거대한 것이 있어서 미리 설명합니다.
- 오늘 얘기는 10%만 GAN의 오리지널 논문에 근거합니다.
- 디테일한 이야기보단 사전지식으로서 가볍게 설명합니다.

# 가짜를 보고 속은 경험이 있나요?

- 진짜같은 가짜 호나우지뉴가 있으니 메시도 속았네요.
- 아마 어머니가 봐도 속을 거예요...

아르헨티나 공격수 리오넬 메시(27·FC바르셀로나)가 훈련도중 경기장으로 난입한 팬을 호나우지뉴(34·아틀레치쿠 미네이루)로 착각하는 사건이 벌어졌다

TOP



fleo\*\*\*\*

딩요 애미도 속겠다

2014.06.12 오후 4:30 신고

# 가짜를 진짜처럼 잘 만들면...


- GAN은 글자 그대로 **생성 모델**이에요.
- 가짜지만 진짜처럼 잘 만들어야 해요.
- 근데 “**진짜같다**”는 걸 누가 **판단**해주죠?

Yann LeCun described GANs as “the most interesting idea in the last 10 years in Machine Learning”.

얀 르쿤이 말하길 GAN은 “지난 10년 동안 머신러닝에서의 가장 흥미로운 아이디어”라고 평했다.

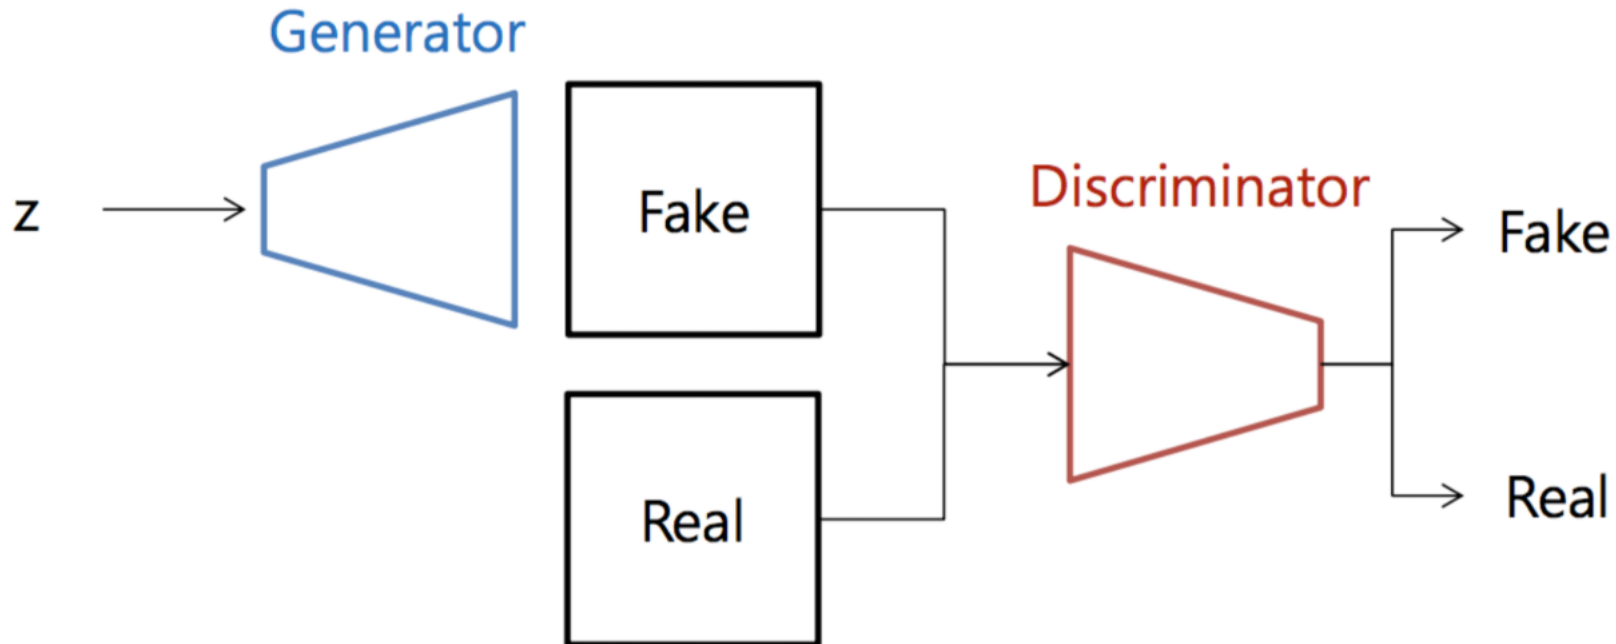
# 아이디어: 위조지폐범과 경찰

- 2014년에 GAN 논문을 발표한 이안 굿펠로우는 위조지폐범과 경찰에 비유했어요.
- 경찰(판별 모델)의 미션: 위조지폐와 실제지폐를 잘 구분해내는 것
- 위조지폐범(생성 모델)의 미션: 위조지폐를 진짜같이 만들어서 경찰을 속이는 것



# 신경망으로 그저 바꿔치면...

- GAN의 학습에서는 신경망 1개가 아니라 2개를 도입해요.
- Discriminator(판별 모델)의 미션: 가짜 데이터와 진짜 데이터를 잘 구분해내기
- Generator(생성 모델)의 미션: 진짜같은 가짜 데이터를 생성해서 판별자를 속이기



# GAN의 손실 함수

- 참고 1:  $D$ 는 데이터를 입력받아 진짜일 확률(0과 1 사이의 실수)을 출력합니다.
- 참고 2:  $G$ 는 노이즈 입력  $z$ 를 받아서 데이터(이미지 등등)를 만들어냅니다.
- 아래 식이 무시무시한가요?  $D$ 와  $G$ 의 미션이 뭐였는지 잊지 마시기 바랍니다.

In other words,  $D$  and  $G$  play the following two-player minimax game with value function  $V(G, D)$ :

$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_{\mathbf{z}}(\mathbf{z})} [\log(1 - D(G(\mathbf{z})))] \quad (1)$$

# GAN의 손실 함수 (cont'd)

- min, max 밑에 G, D라고 적혀있는 걸 보니, 실수 공간에서 최대화를 하는 게 아니라 함수 공간에서 최적화를 하네요.
- 즉, 손실함수를 최적화하는 파라미터(실수)를 찾는 게 아니라 그냥 신경망(함수) G, D를 찾음
- 근데 왜 **G** 입장에선 **최소화**를 하고 **D** 입장에선 **최대화**를 할까요?

$$\min_{\underset{G}{D}} \max_{\underset{D}{D}} E_{x \sim p_{data}} [\log D(x)] + E_{z \sim p_z} [\log(1 - D(G(z)))]$$



# GAN의 손실 함수 (cont'd)

- 아래 식의  $x$ 는 진짜 데이터입니다.  $z$ 는 노이즈입니다.
- $D(x)$ 는 판별 모델이 진짜 데이터를 진짜라고 예측한 확률입니다.
- 로그는 underflow를 막기 좋은 수단입니다.
- 기대값은 전체 데이터의 정보를 말할 수 있는 좋은 수단입니다.

$$E_{x \sim p_{data}} [\log D(x)] + E_{z \sim p_z} \left[ \log \left( 1 - D(G(z)) \right) \right]$$

# GAN의 손실 함수 (cont'd)

- $G(z)$ 는 가짜 데이터입니다.
- $D(G(z))$ 는 판별 모델이 가짜 데이터를 진짜라고 예측한 확률입니다.
- $1-D(G(z))$ 는 판별 모델이 가짜 데이터를 가짜라고 예측한 확률입니다.
- 로그, 기대값을 똑같이 씁니다.

$$E_{x \sim p_{data}} [\log D(x)] + E_{z \sim p_z} [\log (1 - D(G(z)))]$$

# GAN의 손실 함수 (cont'd)

- 그러니까 아래 식의 의미는:

“진짜 데이터는 진짜라고 예측할 평균적 (로그)확률  
+ 가짜 데이터는 가짜라고 예측할 평균적 (로그)확률”

- 이런 의미를 가진 식을 D와 G 입장에선 어떻게 최적화해야 할까요?
- D와 G의 역할을 까먹은 건 아니죠?

$$E_{x \sim p_{data}} [\log D(x)] + E_{z \sim p_z} [\log (1 - D(G(z)))]$$

# GAN의 손실 함수 (cont'd)

- D의 입장에선 진짜 데이터는 진짜라고, 가짜 데이터를 가짜 데이터라고 잘 골라내야 할 임무가 있습니다.
- 그러니까 아래 식을 최대화해야 하는 것이죠:  
“진짜 데이터는 진짜라고 예측할 평균적 (로그)확률  
+ 가짜 데이터는 가짜라고 예측할 평균적 (로그)확률”

$$\max_D E_{x \sim p_{data}} [\log D(x)] + E_{z \sim p_z} [\log (1 - D(G(z)))]$$

# GAN의 손실 함수 (cont'd)

- G는 D와 경쟁하는 (적대적) 입장에 있습니다.
- 그래서 Discriminator와 반대되는 일을 합니다.
- $E_{x \sim p_{data}} [\log D(x)] + E_{z \sim p_z} [\log(1 - D(G(z)))]$  이 커지는 것은 그 의미 상 Generator에게 손해  
이므로 G 입장에서선 줄이려 노력해야 합니다.

(더 정확히는, D에 대해 **최대화된 값을 최소화**합니다.)

$$\arg \min_G \max_D E_{x \sim p_{data}} [\log D(x)] + E_{z \sim p_z} [\log (1 - D(G(z)))]$$

# 참고: GAN의 학습

- D를 먼저 학습하고 G를 학습하는 것에 유의

---

**Algorithm 1** Minibatch stochastic gradient descent training of generative adversarial nets. The number of steps to apply to the discriminator,  $k$ , is a hyperparameter. We used  $k = 1$ , the least expensive option, in our experiments.

---

**for** number of training iterations **do**

**for**  $k$  steps **do**

- Sample minibatch of  $m$  noise samples  $\{z^{(1)}, \dots, z^{(m)}\}$  from noise prior  $p_g(z)$ .
- Sample minibatch of  $m$  examples  $\{x^{(1)}, \dots, x^{(m)}\}$  from data generating distribution  $p_{\text{data}}(x)$ .
- Update the discriminator by ascending its stochastic gradient:

$$\nabla_{\theta_d} \frac{1}{m} \sum_{i=1}^m \left[ \log D(x^{(i)}) + \log \left( 1 - D(G(z^{(i)})) \right) \right].$$

**end for**

- Sample minibatch of  $m$  noise samples  $\{z^{(1)}, \dots, z^{(m)}\}$  from noise prior  $p_g(z)$ .
- Update the generator by descending its stochastic gradient:

$$\nabla_{\theta_g} \frac{1}{m} \sum_{i=1}^m \log \left( 1 - D(G(z^{(i)})) \right).$$

**end for**

The gradient-based updates can use any standard gradient-based learning rule. We used momentum in our experiments.

---

# 참고: GAN의 학습

- GAN의 학습은 Generator의 출력 분포를 데이터의 분포에 가깝게 만드는 역할 수행

**Theorem 1.** *The global minimum of the virtual training criterion  $C(G)$  is achieved if and only if  $p_g = p_{data}$ . At that point,  $C(G)$  achieves the value  $-\log 4$ .*

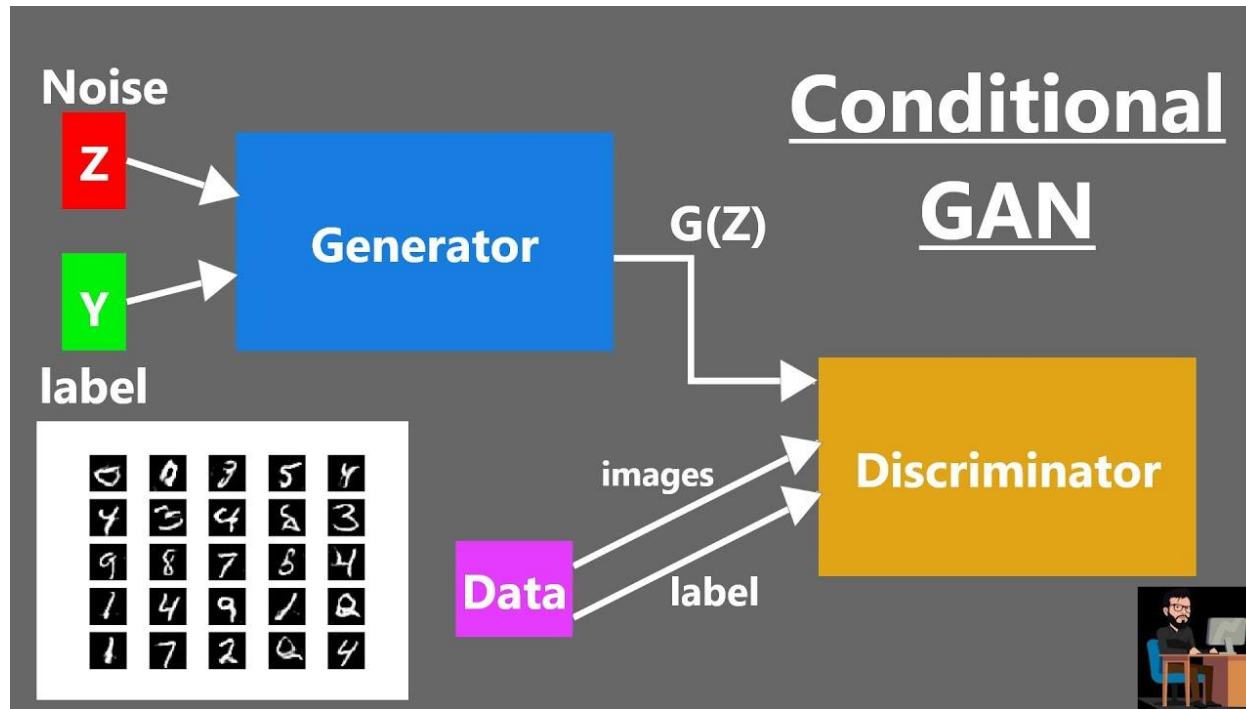
**Proposition 2.** *If  $G$  and  $D$  have enough capacity, and at each step of Algorithm 1, the discriminator is allowed to reach its optimum given  $G$ , and  $p_g$  is updated so as to improve the criterion*

$$\mathbb{E}_{\mathbf{x} \sim p_{data}} [\log D_G^*(\mathbf{x})] + \mathbb{E}_{\mathbf{x} \sim p_g} [\log(1 - D_G^*(\mathbf{x}))]$$

*then  $p_g$  converges to  $p_{data}$*

# GAN에 추가 정보를 같이 섞으면?

- conditional GAN(cGAN)은 데이터(x) 이외에 추가 정보(y)를 넣을 수 있습니다.
- 추가 정보 예시: 이미지의 레이블(클래스)나 다른 modality의 데이터 등
- 기존의 GAN에선 할 수 없었던, 생성되는 데이터를 조절하는 일이 가능해집니다.





# GAN에 추가 정보를 같이 섞으면?

- 아래 보면 알겠지만 더 설명할 건 이게 다예요. 거의 동일해요.
- 추가 정보  $y$ 는 조건부로 들어가요.

In the generator the prior input noise  $p_z(z)$ , and  $y$  are combined in joint hidden representation, and the adversarial training framework allows for considerable flexibility in how this hidden representation is composed.<sup>1</sup>

In the discriminator  $x$  and  $y$  are presented as inputs and to a discriminative function (embodied again by a MLP in this case).

The objective function of a two-player minimax game would be as Eq 2

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{\text{data}}(x)} [\log D(x|y)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z|y)))]. \quad (2)$$

# GAN에 추가 정보를 같이 섞으면?

- 실제 결과들




Figure 2: Generated MNIST digits, each row conditioned on one label

# 이제 다시 질문에 답할 차례입니다

- GAN은 글자 그대로 **생성 모델**이에요.
- 가짜지만 진짜처럼 잘 만들어야 해요.
- 근데 “진짜같다”는 걸 누가 판단해주죠?

In other words,  $D$  and  $G$  play the following two-player minimax game with value function  $V(G, D)$ :

$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_{\mathbf{z}}(\mathbf{z})} [\log(1 - D(G(\mathbf{z})))] \quad (1)$$

# 다음 시간에 다룰 주제

- pix2pix

